



电子科技大学（深圳）高等研究院

Shenzhen Institute for Advanced Study, UESTC



数据智能研究中心

Data Intelligence Group

边缘视觉智能研究进展

组会报告

汇报人：许新操

电子科技大学（深圳）高等研究院

2026年2月8日

- 1 个人简介**
- 2 研究背景**
- 3 研究内容**
- 4 后续计划**

个人基本信息

基本信息



- 许新操 (出生年月: 1994.11)
- 重庆大学 工学博士 (2023.06)
- 电子科大深研院 博士后 (2023.07)
- 电子科大深研院 副研究员 (2025.09)
- 研究方向: 边缘视觉智能

主持省/部级项目

- ✓ 2025年广东省自然科学基金面上项目入选者
- ✓ 2023年中国博士后科学基金面上资助入选者



代表性学术成果

- IEEE T-ITS 2024: 车路协同下异构信息实时融合与有效性评估, 提升协同感知效率
- IEEE TCE 2024: 数字孪生构建中的感知-上传-资源分配联合优化, 提升数字孪生质量
- ECAI 2025: 基于小波解耦与对比学习的跨模态交互表征, 提升感知数据特征鲁棒性与泛化
- JSA 2023: NOMA环境下任务高效卸载与计算资源协同, 提升复杂通信服务成功率
- 电子学报 2021: 边缘计算中的同信道干扰抑制与资源调度, 提升任务完成率与信道利用率

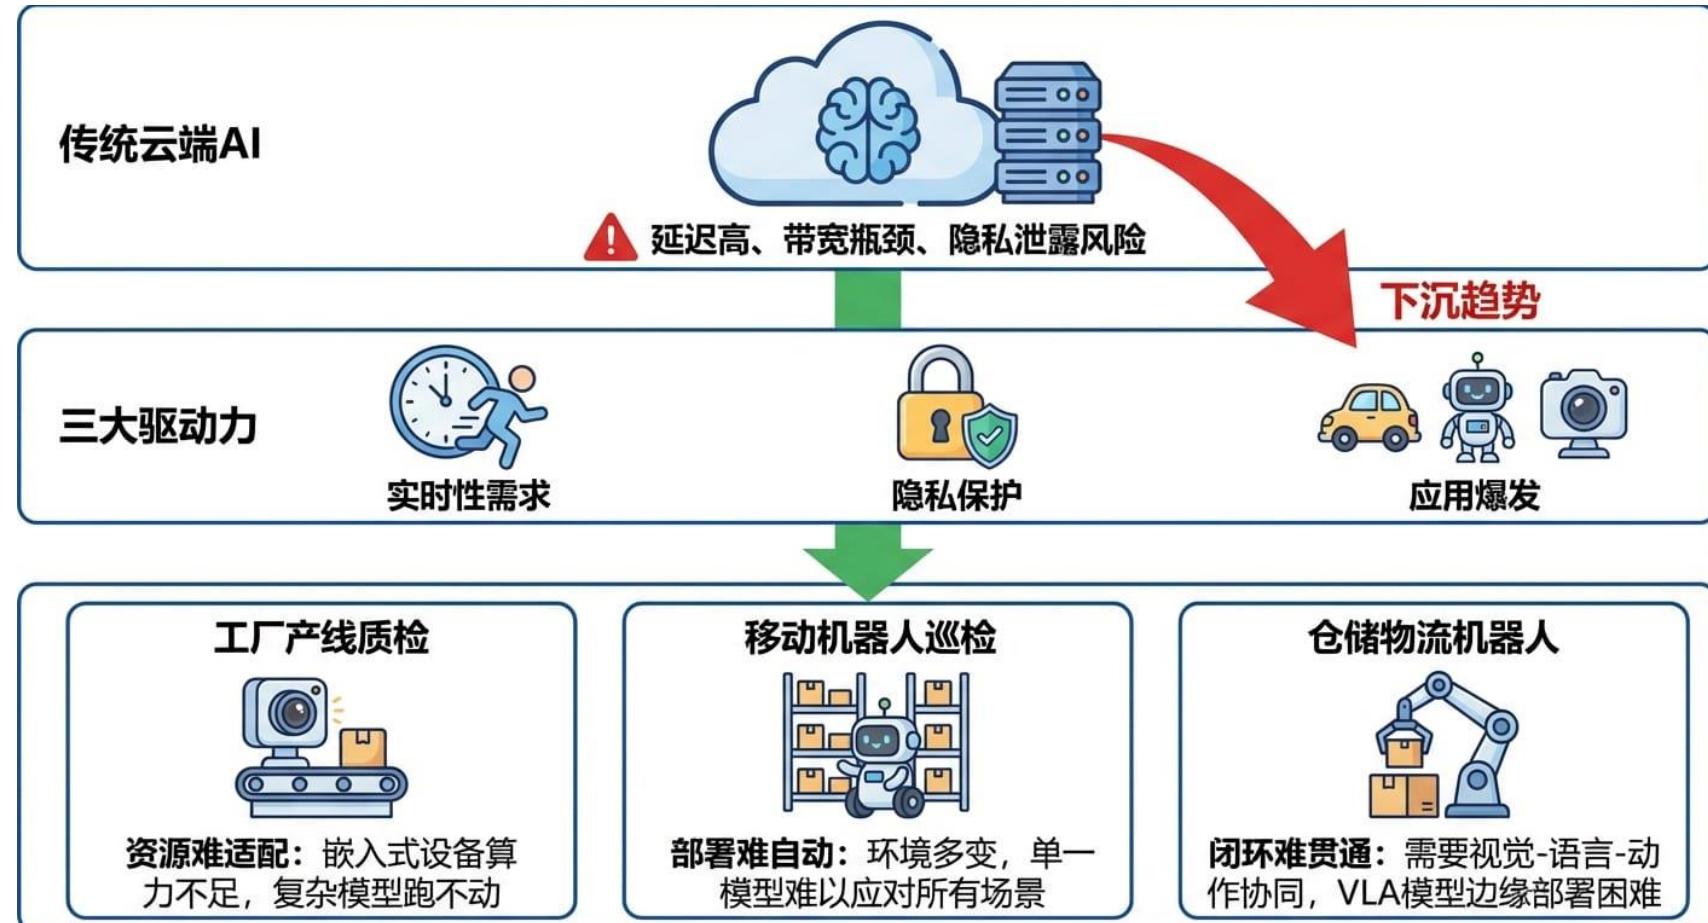


- 1** 个人简介
- 2** 研究背景
- 3** 研究内容
- 4** 后续计划

研究背景：边缘视觉智能趋势与挑战

5

- 趋势一：视觉AI从云端下沉到边缘（实时性、隐私保护需求）
- 趋势二：应用场景爆发（自动驾驶、工业机器人、智能安防）
- 趋势三：设备形态多样（从服务器到MCU）
- 面临挑战
 - 资源难适配
 - 部署难自动
 - 闭环难贯通



边缘视觉智能算力适配、模型部署、系统闭环三重挑战亟待突破

研究背景：边缘视觉智能

挑战

资源难适配

部署难自动

闭环难贯通

关键问题

科学问题

异构资源约束下模型-设备协同优化机理

科学问题

LLM驱动的架构搜索与反馈演化机制

科学问题

边缘VLA模型压缩与快速适应耦合优化机理

研究内容

协同推理

异构边缘设备的重叠部署与动态执行调度机制

模型定制

LLM驱动端侧模型自动化生成与硬件感知优化

系统实现

资源受限条件下VLA的压缩-适应协同优化

目标

在资源受限、动态异构的边缘环境下，实现从算法→部署→应用的闭环



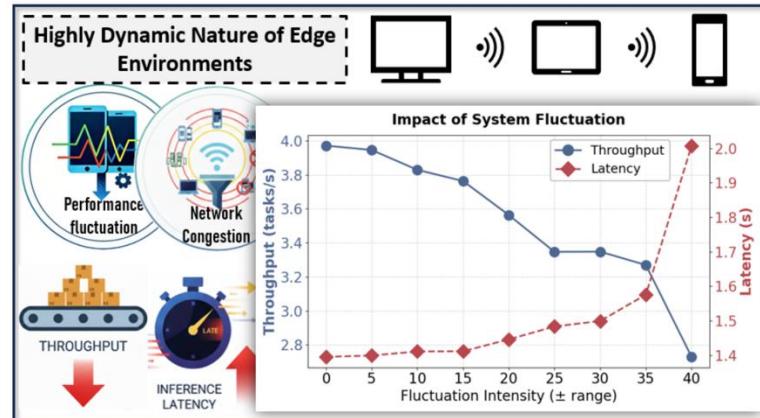
- 1** 个人简介
- 2** 研究背景
- 3** 研究内容
- 4** 后续计划

研究内容一：异构边缘协同推理

背景

边缘流水线推理：资源波动/设备故障，重部署方案开销大，只优化吞吐量

研究
内
容



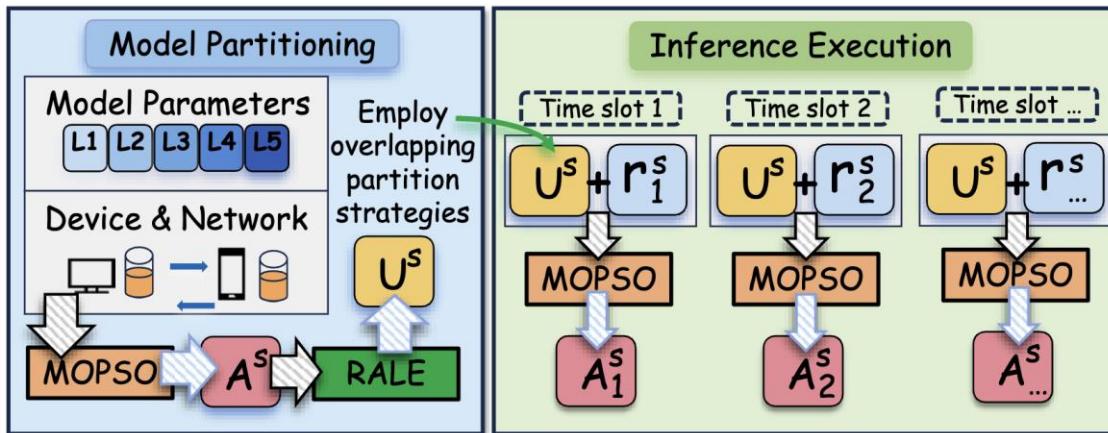
- **系统建模：**提出边缘流水线的重叠部署与动态执行系统模型，建立可靠性-吞吐量联合优化模型
- **调度框架：**构建部署-执行解耦的两阶段优化流程，支持无需重部署的实时自适应推理调度
- **算法设计：**提出 MOPSO 多目标分区算法与 RALE 冗余扩展算法，成功率最高 $\uparrow 8.7$ 倍，吞吐量 $\uparrow 1.4$ 倍

相关
成
果

- 已投稿 1 篇论文：投至 IEEE/ACM TON (CCF A 类国际期刊)
- 下一步工作：研究Transformer架构下Prefill与Decode阶段的异构多设备并行调度优化

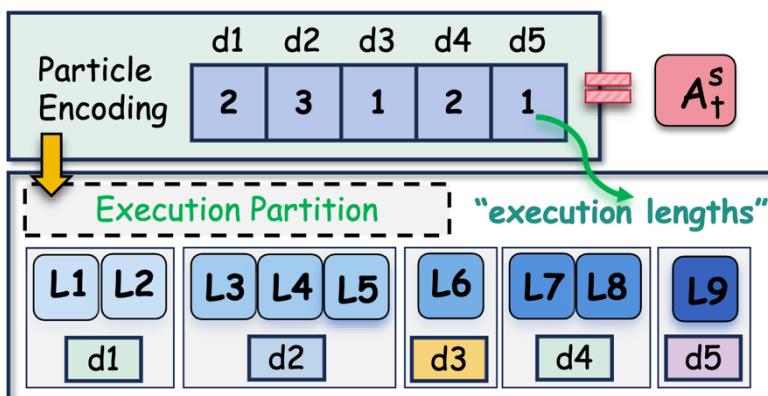
重叠部署 + 动态执行，通过冗余存储实现故障容忍，无需频繁重部署

研究内容一：两阶段优化框架



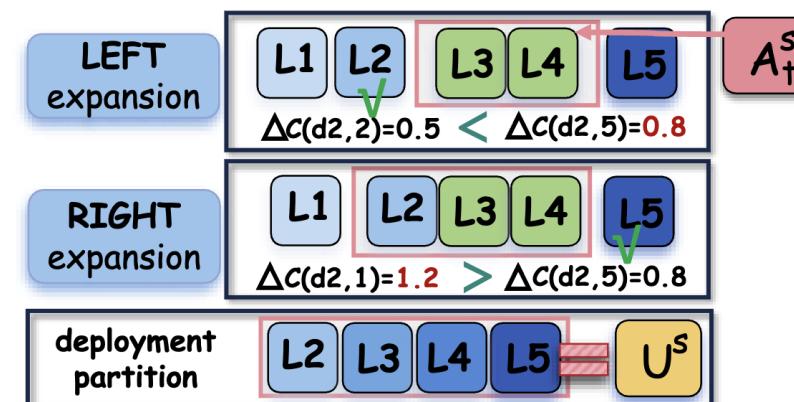
阶段	算法	作用
部署阶段	MOPSO + RALE	确定重叠部署方案
执行阶段	MOPSO	动态选择执行分区

MOPSO: 多目标粒子群优化



- 粒子编码：每维表示设备执行的层数
- 双目标：最大化吞吐量 + 可靠性

RALE: 冗余感知层扩展

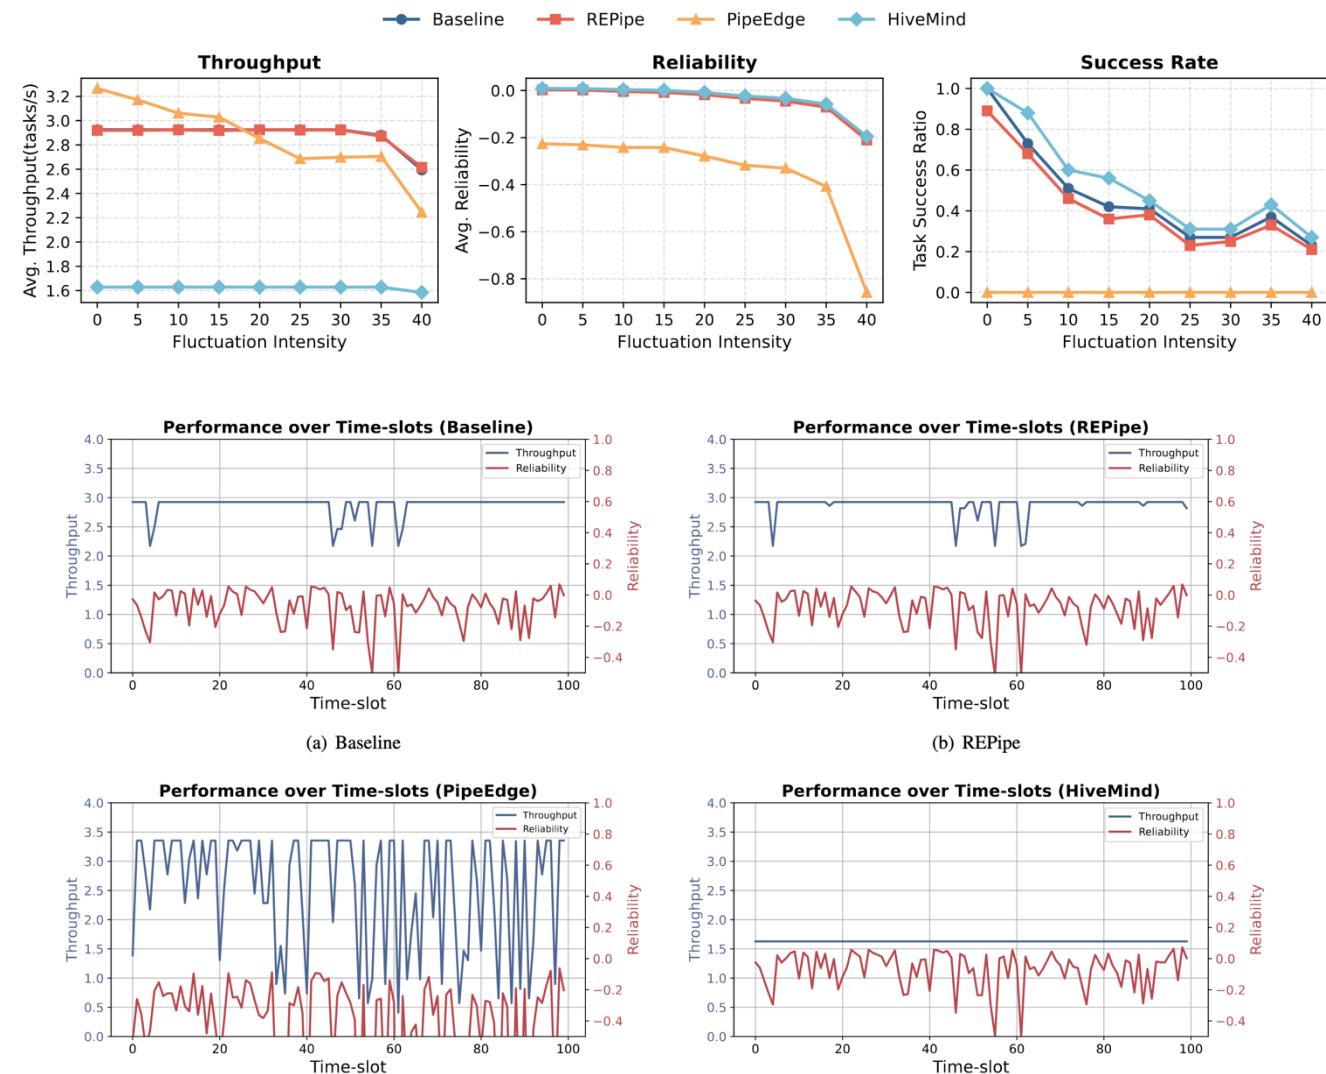
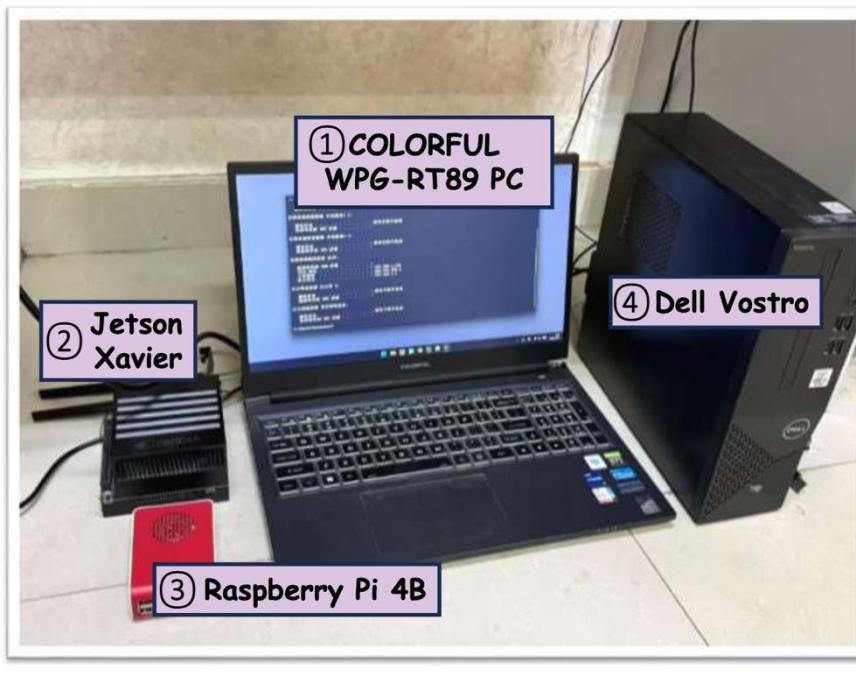


- 从执行分区出发，贪心扩展存储范围
- 优先扩展增量负载小的方向（左/右）

研究内容一：实验结果

实验配置

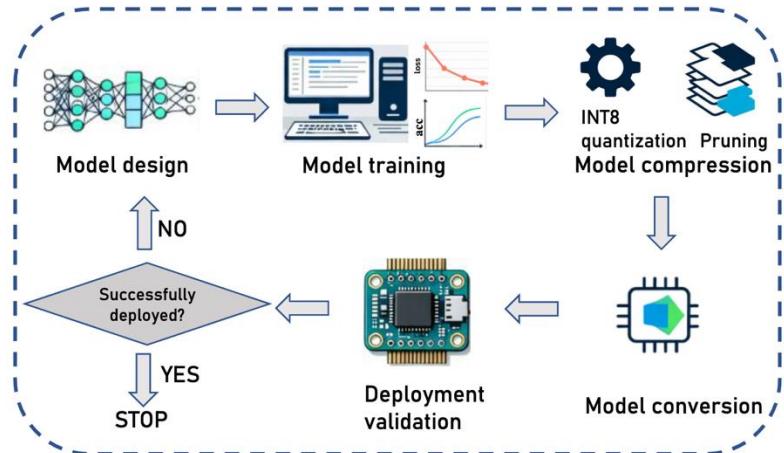
- 仿真：100个执行周期，资源动态波动
- 真实测试床：4台异构设备（PC/Jetson/树莓派）
- 模型：VGG19、YOLONet、ResNet50



背景

MCU资源极度受限：压缩/轻量化设计，HW-NAS搜索成本高，人工介入

研究 内容



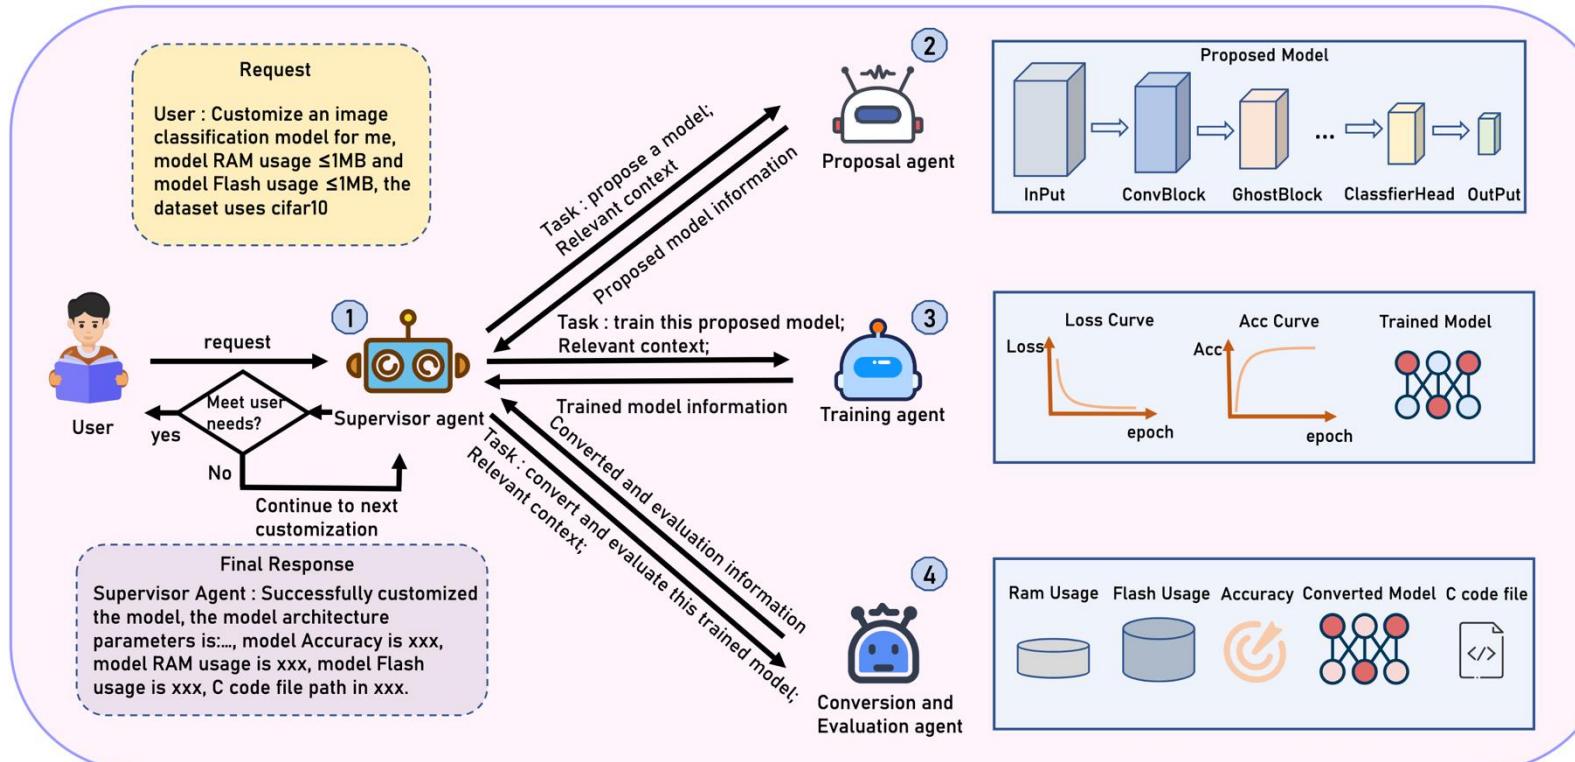
- **端到端框架：**实现从自然语言需求到可部署C代码的全流程自动化模型定制，比传统方法快100倍以上
- **硬件感知机制：**设计硬件在环过滤与历史性能库双重反馈机制，在训练前验证架构可行性并引导高效收敛
- **智能体调度：**提出状态隔离的多智能体调度机制，通过结构化摘要通信确保长周期优化过程的稳定性与可控性

相关 成果

- 已投稿 1 篇论文：投至 IEEE TMC (CCF A 类/中科院 1 区国际期刊)
- 下一步工作：研究MCU端模型的自动调试与故障诊断机制，并扩展至GPU/NPU/FPGA等异构设备

端到端自动化：自然语言需求→可部署C代码，LLM推理能力替代NAS搜索

研究内容二：多智能体协同框架



□ Supervisor

- ✓ 任务分解与调度
- ✓ 集中控制，状态隔离

□ Proposal Agent

- ✓ 生成候选架构
- ✓ 硬件可行性过滤 + 历史性能学习

□ Training Agent

- ✓ 训练与早停
- ✓ 有限预算内评估性能

□ Eval & Convert

- ✓ 资源评估+C代码生成
- ✓ STM32Cube.AI工具链验证

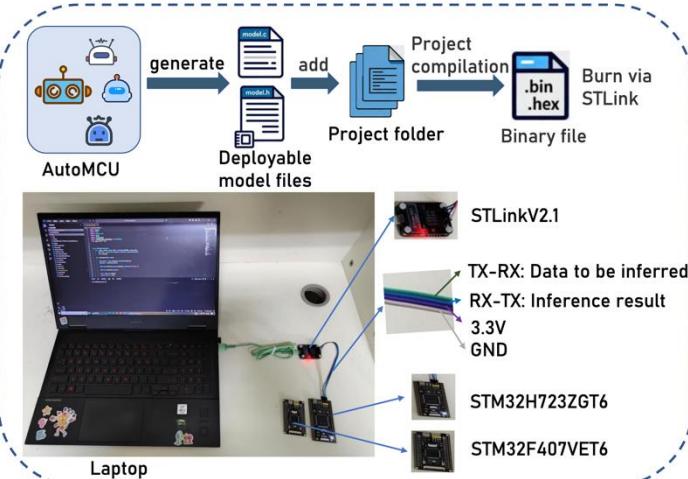
研究内容二：实验结果

14

实验配置

- 数据集：CIFAR-10 / CIFAR-100
- 硬件约束：RAM \leq 256KB,
Flash \leq 512KB
- 真实设备：STM32F4/F7/H7系列

MCU

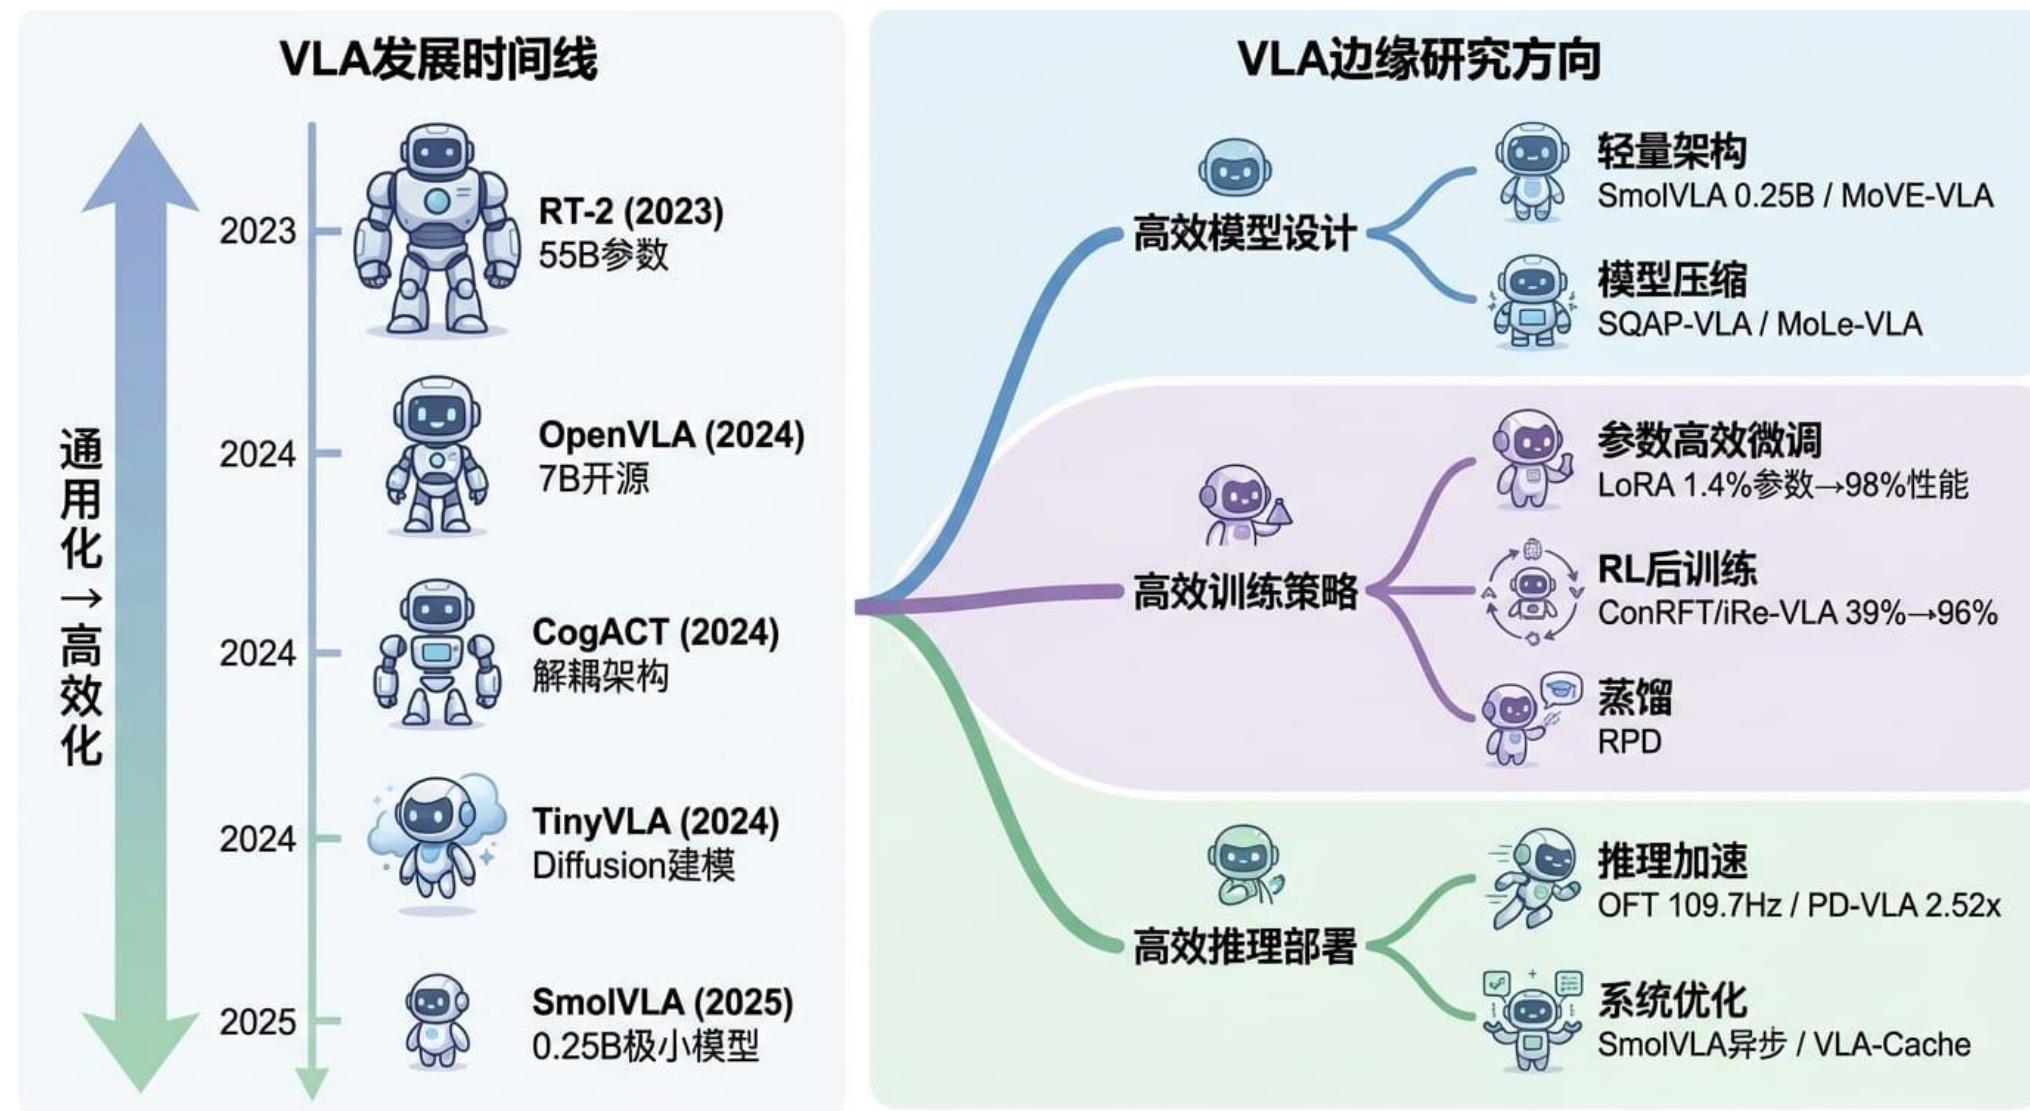


Model	CIFAR10				
	Accuracy (%) \uparrow	RAM (KB) \downarrow	Flash (KB) \downarrow	Time (GPU Hours) \downarrow	Cost (\$) \downarrow
MobileNetV2 [21]	84.50	110.44	8670.41	N/A	N/A
ShuffleNetV2 [22]	79.34	24.00	4905.33	N/A	N/A
SqueezeNet [51]	82.91	72.00	2892.79	N/A	N/A
MCUNet-in2 [16]	83.69	<u>42.63</u>	2197.57	N/A	N/A
MnasNet [17]	83.61	54.75	12094.38	N/A	N/A
FairNAS-C [18]	84.25	56.44	12159.85	N/A	N/A
μ NAS_1024 [20]	89.75	1159.99	2902.15	257.48	53.35
AutoMCU_1024 (DeepSeek-V3.2)	89.31 ± 0.16	218.81 ± 70.71 [135.00 , 364.31]	848.97 ± 99.16 [724.85 , 988.67]	1.58 ± 1.07	0.45 ± 0.31
AutoMCU_1024 (MiMo-V2-Flash)	89.30 ± 0.34	210.24 ± 65.74 [128.00 , 384.00]	876.00 ± 126.11 [629.28 , 1015.82]	1.00 ± 0.48	0.23 ± 0.11
AutoMCU_1024 (qwen-plus)	88.77 ± 0.46	185.66 ± 59.76 [83.38 , 257.12]	888.31 ± 98.52 [707.18 , 1006.38]	1.54 ± 1.04	0.47 ± 0.30
μ NAS_256 [20]	87.88	580.92	872.34	173.87	36.03
AutoMCU_256 (DeepSeek-V3.2)	87.62 ± 0.52	124.84 ± 23.80 [83.38 , 160.00]	466.55 ± 34.61 [402.77 , 504.52]	1.56 ± 1.25	0.45 ± 0.37

Model	CIFAR100				
	Accuracy (%) \uparrow	RAM (KB) \downarrow	Flash (KB) \downarrow	Time (GPU Hours) \downarrow	Cost (\$) \downarrow
MobileNetV2 [21]	50.70	110.44	9120.77	N/A	N/A
ShuffleNetV2 [22]	44.73	24.00	5265.68	N/A	N/A
SqueezeNet [51]	42.82	72.00	3073.14	N/A	N/A
MCUNet-in2 [16]	51.06	<u>42.63</u>	2254.17	N/A	N/A
MnasNet [17]	52.34	54.75	12544.73	N/A	N/A
FairNAS-C [18]	45.75	56.44	12610.20	N/A	N/A
μ NAS_1024 [20]	60.26	1024.10	2522.94	188.60	39.08
AutoMCU_1024 (DeepSeek-V3.2)	61.63 ± 0.50	157.35 ± 49.24 [112.50 , 257.12]	861.72 ± 81.10 [674.17 , 958.78]	0.72 ± 1.00	0.25 ± 0.31
AutoMCU_1024 (MiMo-V2-Flash)	61.63 ± 0.42	183.13 ± 65.27 [93.80 , 289.00]	872.20 ± 82.83 [728.46 , 1013.46]	1.28 ± 1.35	0.32 ± 0.34
AutoMCU_1024 (qwen-plus)	61.55 ± 0.81	201.52 ± 43.28 [125.06 , 256.00]	866.86 ± 116.07 [680.83 , 1008.65]	0.83 ± 0.56	0.24 ± 0.15
μ NAS_256 [20]	58.82	349.00	1448.15	160.80	33.32
AutoMCU_256 (DeepSeek-V3.2)	58.70 ± 0.71	138.21 ± 57.10 [72.95 , 256.00]	481.49 ± 28.43 [430.25 , 509.80]	2.43 ± 1.15	0.76 ± 0.37

研究内容三：边缘高效VLA

15

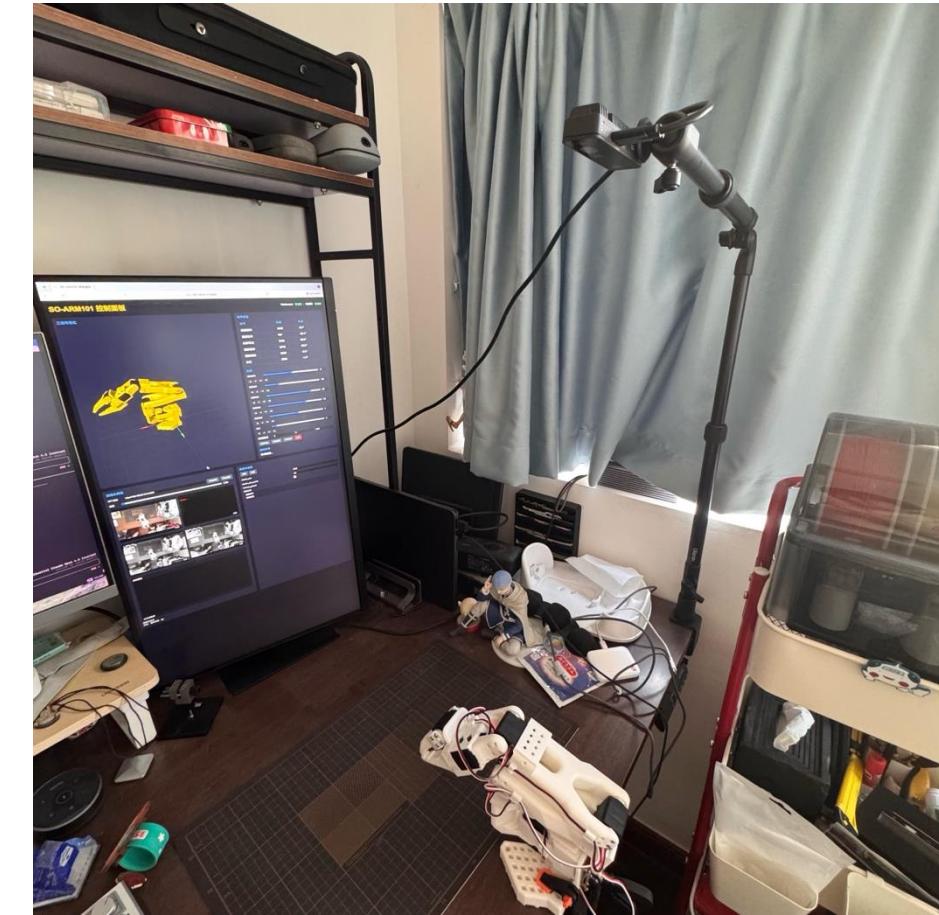
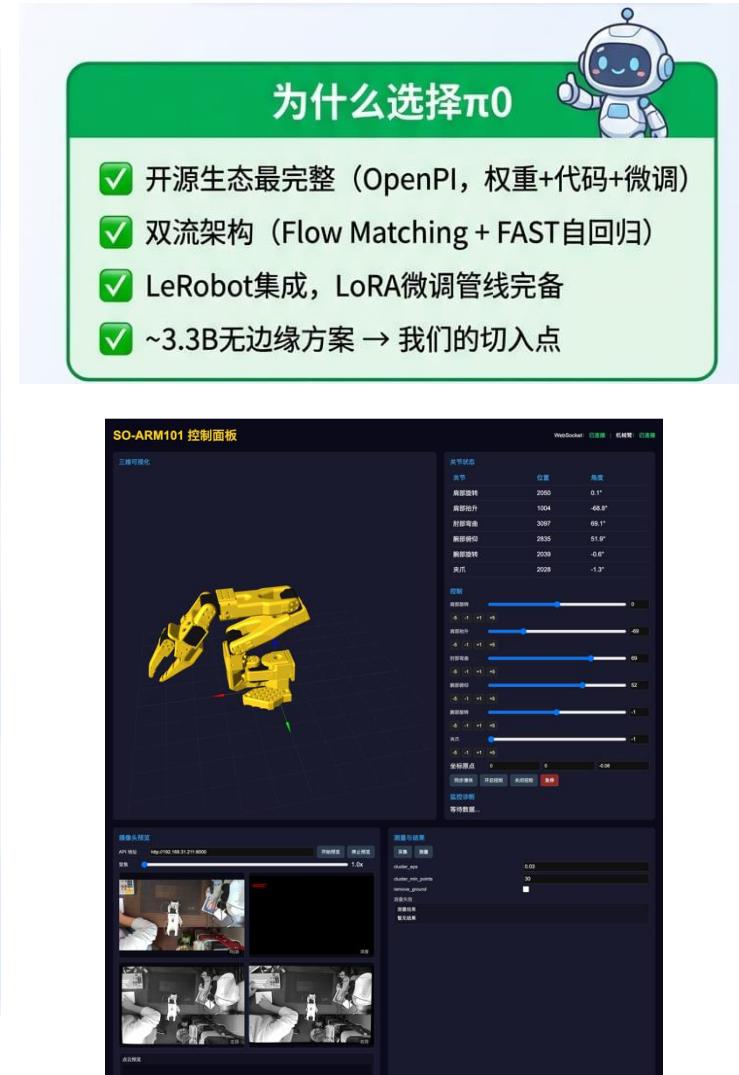
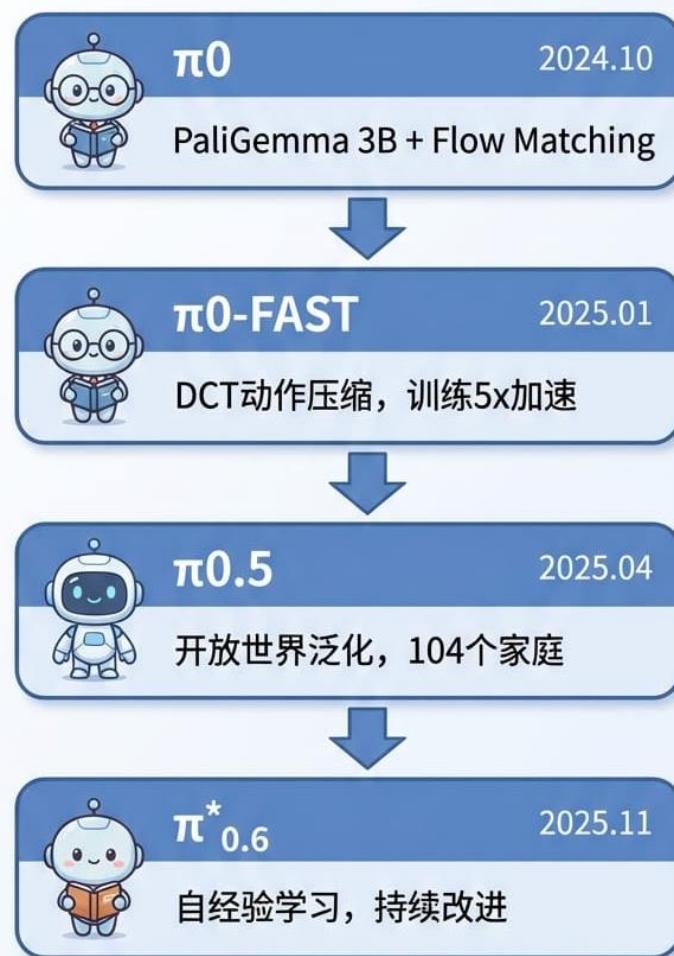


研究内容三：边缘高效VLA

架构优化

泛化能力增强

持续学习能力提升



- 1 个人简介**
- 2 研究背景**
- 3 研究内容**
- 4 后续计划**

后续计划：研究进展

18

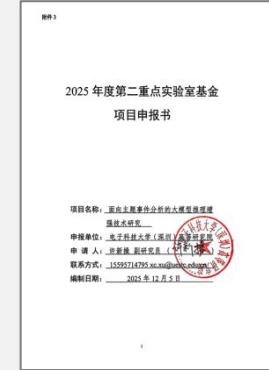
论文发表/投稿情况

- **IEEE TMC**: 2026年1月8日以通讯作者投稿中科院1区/CCF A类国际期刊论文1篇
- **IEEE TMC**: 2026年1月21日以通讯作者投稿中科院1区/CCF A类国际期刊论文1篇
- **IEEE TWC**: 2026年1月27日以通讯作者投稿中科院1区国际期刊论文1篇
- **IEEE/ACM TON**: 2026年1月29日以通讯作者投稿中科院1区/CCF A类国际期刊论文1篇
- **IEEE TNSE**: 2025年2月2日以通讯作者返修中科院2区国际期刊论文1篇 (Minor)



项目申报/参与情况

- 2025年12月5日申报中电10所第二重点实验室基金项目1项，经费20万，并参加答辩环节
- 2025年10月20日参与北理牵头平安中国重点专项子课题1项



奖项获得情况

- 2025年11月28日获得IEEE ISPCE-AS 国际会议最佳论文奖



后续计划：工作目标

19

短期目标

方向	目标与时间	产出
异构边缘协同推理	期刊论文扩展投稿 (3/4月)	CCF A 会议论文投稿
端侧模型定制与部署	期刊论文扩展投稿 (3/4月)	CCF A 会议论文投稿
边缘高效VLA	确定具体研究内容 (1个月内)	研究Proposal

中期目标

方向	目标与时间	产出
科研论文	视觉推理+边缘部署联合工作	至少 1 篇论文
边缘高效VLA	完成1篇工作并投稿 (1年内)	至少 1 篇论文
项目申报	参与团队项目申报	基金申请书



电子科技大学（深圳）高等研究院

Shenzhen Institute for Advanced Study, UESTC



数据智能研究中心

Data Intelligence Group

感谢聆听

THANKS FOR YOUR ATTENTION

许新操 | 数据智能研究中心

Powered by:



<https://github.com/openclaw/openclaw>

<https://github.com/ResearAI/AutoFigure-Edit>